

1. Введение

Датасет: из соревнования Diabetes Prediction Challenge (Kaggle)

Источник: <https://www.kaggle.com/competitions/playground-series-s5e12/data>

Датасет содержит медицинские и демографические данные и предназначен для бинарной классификации — предсказания наличия диагностированного диабета

(diagnosed_diabetes: 0 или 1).

В наборе 26 столбцов: числовые показатели здоровья (ИМТ, давление, пульс, холестерин), факторы образа жизни (физическая активность, диета, сон, экранное время), демографические признаки (пол, этничность, образование, доход) и медицинский анамнез (семейная история диабета, гипертензия, сердечно-сосудистые заболевания).

LLM: Claude (Anthropic).

2. Промпт 1: Понимание структуры данных

Текст промпта

У меня есть датасет для предсказания диабета (train.csv) с 700 000 строк и 26 столбцами. Столбцы: id, age, alcohol_consumption_per_week, physical_activity_minutes_per_week, diet_score, sleep_hours_per_day, screen_time_hours_per_day, bmi, waist_to_hip_ratio, systolic_bp, diastolic_bp, heart_rate, cholesterol_total, hdl_cholesterol, ldl_cholesterol, triglycerides, gender, ethnicity, education_level, income_level, smoking_status, employment_status, family_history_diabetes, hypertension_history, cardiovascular_history, diagnosed_diabetes. Целевая переменная — diagnosed_diabetes (0/1). Опиши структуру данных: какие типы признаков присутствуют, какие из них числовые, какие категориальные, какие бинарные. Предположи, какие проблемы с качеством данных могут встретиться.

Ответ LLM

LLM классифицировала 26 столбцов следующим образом:

Числовые непрерывные (15): age, alcohol_consumption_per_week, physical_activity_minutes_per_week, diet_score, sleep_hours_per_day, screen_time_hours_per_day, bmi, waist_to_hip_ratio, systolic_bp, diastolic_bp, heart_rate, cholesterol_total, hdl_cholesterol, ldl_cholesterol, triglycerides.

Категориальные номинальные (6): gender (Male/Female/Other), ethnicity (5 значений), education_level (4 значения), income_level (5 значений), smoking_status (3 значения), employment_status (4 значения).

Бинарные (4): family_history_diabetes, hypertension_history, cardiovascular_history, diagnosed_diabetes.

Технический (1): id.

LLM предположила возможные проблемы с качеством: пропущенные значения, выбросы в BMI и артериальном давлении, дисбаланс классов в целевой переменной, мультиколлинеарность между компонентами холестерина ($\text{cholesterol_total} \approx \text{HDL} + \text{LDL} + \text{triglycerides}/5$ по формуле Фридвальда), необходимость кодирования категориальных признаков.

Мой комментарий

LLM верно предположила мультиколлинеарность компонентов холестерина по формуле Фридвальда, что действительно может привести к нестабильности коэффициентов в линейных моделях. Однако модель ошиблась в предположении о пропущенных значениях — при проверке данных выяснилось, что в датасете нет ни одного пропуска, что нетипично для реальных медицинских данных и указывает на предварительную очистку или синтетическую генерацию. Также LLM не обратила внимания на непропорционально большой объём данных (700 000 записей), нехарактерный для клинических исследований, что дополнительно подтверждает искусственную природу набора.

3. Промпт 2: Тренды образа жизни и диабет

Текст промпта

Проанализируй связь между образом жизни и диагнозом диабета в моём датасете. Вот статистика: для группы с диабетом ($\text{diagnosed_diabetes}=1$, $n=436\,307$): средняя физическая активность 73.5 мин/нед, средний diet_score 5.91, средний BMI 26.1, среднее потребление алкоголя 2.07 ед/нед, средний сон 7.00 ч/день, среднее экранное время 6.04 ч/день. Для группы без диабета ($n=263\,693$): средняя физическая активность 91.4 мин/нед, средний diet_score 6.06, средний BMI 25.5, алкоголь 2.07, сон 7.00, экранное время 5.97. Какие тренды ты видишь? Какие факторы наиболее выражены?

Ответ LLM

LLM выделила следующие тренды:

1. **Физическая активность** — сильнейший дифференциатор: группа с диабетом в среднем тратит 73.5 мин/нед против 91.4 мин/нед у здоровых, что составляет снижение на 24%. Это согласуется с медицинской литературой о сидячем образе жизни как факторе риска.
2. **ВМІ** показывает умеренную, но устойчивую разницу (26.1 vs 25.5) — оба значения вблизи порога избыточного веса (25), но группа с диабетом его пересекает.
3. **Diet score** различается минимально (5.91 vs 6.06), что говорит о слабой дискриминативной способности качества диеты.
4. **Потребление алкоголя** идентично (2.07 vs 2.07) — тренд отсутствует.
5. **Сон и экранное время** практически не различаются между группами.

Также модель отметила, что общая распространённость диабета составляет 62.3%, что крайне нереалистично для генеральной популяции.

Мой комментарий

Наиболее значимым наблюдением является разница в физической активности: 24% снижение у группы с диабетом — это клинически значимый результат, согласующийся с рекомендациями ВОЗ о минимуме 150 минут умеренной активности в неделю (обе группы далеки от этого порога). LLM справедливо указала на подозрительно высокую распространённость диабета в 62.3%, тогда как в реальных популяциях этот показатель составляет 8–12% по данным ВОЗ, что подтверждает гипотезу о синтетической генерации с искусственно смещённым балансом классов. Удивительно, что потребление алкоголя абсолютно не различается между группами — в реальности связь, как правило, нелинейная (U-образная кривая), но при усреднении эффект теряется.

4. Промпт 3: Обнаружение аномалий в данных о здоровье

Текст промпта

В моём датасете о диабете обнаружены следующие диапазоны значений: `physical_activity_minutes_per_week`: min=1, max=747, mean=80.2; `BMI`: min=15.1, max=38.4; `systolic_bp`: min=91, max=163; `heart_rate`: min=42, max=101; `sleep_hours_per_day`: min=3.1, max=9.9; `screen_time_hours_per_day`: min=0.6, max=16.5; `waist_to_hip_ratio`: min=0.68, max=1.05. Также: 7 244 записи с активностью >300 мин/нед, 522 записи с BMI>35, 41 запись с экранным временем >14 ч/день. Выяви аномалии и потенциальные выбросы. Какие значения выглядят подозрительно с медицинской точки зрения?

Ответ LLM

LLM проанализировала диапазоны с медицинской точки зрения:

1. **Физическая активность max=747 мин/нед** (≈ 107 мин/день, 7 дней) — экстремально, но физически возможно для профессиональных спортсменов. 7 244 записи с >300 мин/нед (>43 мин/день) вполне правдоподобны для активных людей.
2. **Экранное время max=16.5 ч/день** — оставляет лишь 7.5 часов на сон и другие активности; подозрительно, но технически возможно.
3. **BMI min=15.1** — соответствует тяжёлому дефициту массы тела (граница анорексии); max=38.4 — ожирение II степени, но подозрительно «обрезан» сверху (в реальных данных встречаются значения до 50+).
4. **Пульс 42–101 уд/мин** — 42 уд/мин характерен для брадикардии (норма у спортсменов), 101 — пограничная тахикардия. Диапазон подозрительно узкий для клинических данных.
5. **Систолическое АД 91–163 мм рт. ст.** — 91 — пограничная гипотензия, 163 — гипертензия II стадии. Отсутствие экстремальных значений нетипично.
6. **Сон 3.1–9.9 часов** — ни одного значения ниже 3 или выше 10, что указывает на искусственное ограничение диапазона.

Мой комментарий

LLM продемонстрировала сильную сторону — способность сопоставить числовые диапазоны с медицинскими нормами, верно отметив, что пульс 42 уд/мин характерен для тренированных спортсменов, а ИМТ 15.1 соответствует тяжёлому дефициту массы тела. Ключевое наблюдение, которое LLM могла бы подчеркнуть сильнее: все числовые признаки имеют подозрительно «чистые» диапазоны без экстремальных выбросов, что нетипично для реальных медицинских данных, где встречаются ошибки ввода и артефакты измерений. Ограничение BMI значением 38.4 сверху особенно показательно — в клинической практике значения выше 40 (морбидное ожирение) достаточно распространены, а их отсутствие подтверждает генерацию данных по заранее заданным распределениям.

5. Промпт 4: Демографические паттерны и медицинский анамнез

Текст промпта

Вот данные о распространённости диабета по подгруппам в моём датасете (700 000 записей). По семейному анамнезу: с семейной историей диабета — 86.7% (n=104 581), без — 58.0% (n=595 419). По гипертензии: с историей — 65.4% (n=127 393), без — 61.6%. По сердечно-сосудистым заболеваниям: с историей — 69.1% (n=21 227), без — 62.1%. По полу: женщины 62.2%, мужчины 62.4%, другое 64.1%. По этничности: White 62.4%, Hispanic 61.6%, Black 62.4%, Asian 62.8%, Other 63.6%. По курению: Current 62.3%, Never 62.3%, Former 62.5%. Проанализируй, какие факторы сильнее всего влияют на диабет. Сформулируй практические выводы для системы здравоохранения.

Ответ LLM

LLM провела анализ:

1. **Семейная история — доминирующий предиктор:** разница в 28.7 п.п. (86.7% vs 58.0%). Это сильнейший одиночный фактор в датасете.
2. **Сердечно-сосудистые заболевания** показывают значимую разницу (69.1% vs 62.1%), как и **гипертензия** (65.4% vs 61.6%).
3. **Пол, этничность и статус курения практически не различаются** (разброс 1–2 п.п.), что означает отсутствие дискриминативной способности.

Практические рекомендации:

- Таргетный скрининг для лиц с семейной историей диабета.
- Интегрированная оценка метаболического и кардиоваскулярного риска.
- Универсальный скрининг вне зависимости от пола/этничности, поскольку риск распределён равномерно.

Мой комментарий

Данные выявляют парадоксальную картину: семейная история диабета является мощнейшим предиктором (разница 28.7 п.п.), тогда как традиционно значимые факторы — пол, этничность, курение — практически не дифференцируют группы. В реальной эпидемиологии этнические различия в распространённости диабета II типа хорошо документированы (например, повышенный риск у афроамериканцев и латиноамериканцев по данным CDC), поэтому их отсутствие является ещё одним признаком синтетической генерации данных. LLM сформулировала разумные рекомендации о таргетном скрининге, но не смогла критически оценить нереалистичность равномерного распределения риска по демографическим группам, принимая данные за истину без дополнительных оговорок.

6. Промпт 5: Итоговые выводы и рекомендации по моделированию

Текст промпта

На основании всего анализа датасета предсказания диабета (700 000 строк, 26 признаков), резюмируй ключевые находки и предложи: (1) какие 5 признаков наиболее важны для предсказания диабета и почему; (2) какие признаки можно исключить без потери качества; (3) какие шаги предобработки необходимы; (4) какой тип модели рекомендуешь и почему. Учитывай дисбаланс классов 62.3% к 37.7%.

Ответ LLM

LLM предложила:

Топ-5 признаков:

1. `family_history_diabetes` — сильнейший одиночный предиктор (86.7% vs 58.0%).
2. `physical_activity_minutes_per_week` — 24% разница между группами.
3. `bmi` — клинически значимая разница (26.1 vs 25.5).
4. `age` — разница в 4 года между средними.
5. `hypertension_history` — сигнал коморбидности.

Признаки для исключения: `id` (технический), один из коллинеарных компонентов холестерина (оставить HDL и триглицериды, исключить `cholesterol_total` и `LDL`), `smoking_status` (нет дискриминативной способности), `gender` и `ethnicity` (разница <2 п.п.).

Предобработка: one-hot кодирование категориальных признаков, стандартизация числовых, создание интерактивных признаков (`age × bmi`, `family_history × physical_activity`).

Рекомендация по модели: Gradient Boosting (XGBoost/LightGBM) как основная модель; логистическая регрессия как интерпретируемый бейзлайн. При дисбалансе 62/38 достаточно стратифицированных разбиений и метрик F1/AUC-ROC, агрессивный ресемплинг не нужен.

Мой комментарий

LLM предложила практически применимую стратегию моделирования, однако допустила характерную ошибку — рекомендуя удалить `cholesterol_total` из-за мультиколлинеарности, она не учла, что для ансамблевых моделей (XGBoost) мультиколлинеарность не является проблемой, в отличие от линейной регрессии. Это типичный пример переноса знаний из одного контекста в другой без адаптации. Рекомендация по инженерии признаков ($\text{age} \times \text{bmi}$, $\text{family_history} \times \text{physical_activity}$) отражает понимание медицинского контекста, где взаимодействие факторов часто важнее их индивидуального вклада. Стоит отметить, что LLM верно определила умеренный дисбаланс классов и не стала рекомендовать агрессивные методы ресемплинга (SMOTE), что свидетельствует о практичном подходе.

7. Заключение

В ходе работы было проведено разведочное исследование датасета предсказания диабета (700 000 записей, 26 признаков) с помощью пяти целенаправленных промптов, охвативших: понимание структуры данных, анализ трендов образа жизни, обнаружение аномалий, демографический анализ и выработку рекомендаций по моделированию.

LLM оказалась наиболее полезна для быстрой генерации гипотез и интерпретации данных в медицинском контексте — модель корректно идентифицировала пороги брадикардии, формулу Фридвальда для холестерина, рекомендации ВОЗ по физической активности.

Ключевое ограничение: LLM не способна самостоятельно вычислять статистику — она полностью полагается на предоставленные ей числа и может уверенно оперировать неверными данными, если ей их передать. Кроме того, модель склонна принимать данные за «чистую монету», не подвергая сомнению их происхождение: LLM не инициативно указала на нереалистичную распространённость диабета в 62.3% и на отсутствие этнических различий, которые хорошо документированы в реальной эпидемиологии.

Оптимальный рабочий процесс для EDA — комбинация LLM для генерации гипотез и интерпретации с Python/Pandas для фактических вычислений и проверки. LLM ускоряет анализ, но не заменяет его — каждый вывод модели требует верификации на реальных данных.